

10. 형식언어

충북대학교

이재성





학습내용

- 형식 언어 정의 방법
- 형식 문법 정의 방법
- 언어 및 문법 계층 구조



알파벳과 스트링

■ 알파벳과 스트링

- 잘 정의된 언어는 문장으로 구성됨
- 알파벳은 문장을 이루는 기본적인 심볼

(1) 알파벳(alphabet)

- 심벌들의 유한 집합
- ex) $T_1 = \{\sqcup, \sqsubset, \sqsubseteq, \dots, \sqsupseteq, \vdash, \models, \dots, \neg, \mid\}$

$$T_2 = \{A, B, C, \dots, Z\}$$

$$T_3 = \{\text{begin}, \text{integer}, \dots, \text{end}\}$$

(2) 스트링(string) (또는 문장, 단어)

- 알파벳 T 에 속하는 하나 이상의 심벌들의 나열

(3) 길이(length)

- 스트링을 이루는 심벌들의 개수
- $|\omega|$ 로 표시

꼭 기억해야 할 세 가지 개념

1. 언어의 정의
2. 문법의 정의 및 개념
3. 인식기의 의미



(4) empty 스트링(empty string)

- 스트링의 길이가 0인 것
- ϵ (epsilon) 또는 λ (lambda)로 표시

(5) T^* 알파벳 T에 대하여 empty 스트링을 포함한 모든 스트링의 집합

$$T^+ = T^* - \{\epsilon\}$$

$\lceil T^* : T \text{ star}$

$\lceil T^+ : T \text{ dagger}$



(6) 접속(concatenation)

- 스트링을 연속으로 연결한 것
- $u = a_1a_2a_3\dots a_n, v = b_1b_2b_3\dots b_m, u \cdot v = a_1a_2a_3\dots a_n b_1b_2b_3\dots b_m$
- $u \cdot v$ 를 보통 uv 로 표기.
- $u\varepsilon = u = \varepsilon u$
- $\forall u, v \in T^*, uv \in T^*$.
- $|uv| = |u| + |v|$

(7) a^n

- n개의 a를 나타낸다.
- $a^0 = \varepsilon$

(8) 문자 ω 의 **반전**은 문자 ω 에 반전 표시를 $(\omega^R)^R = \omega$ 로 표시한다.
i.e., if $\omega = a_1a_2\dots a_n$ then $\omega^R = a_na_{n-1}\dots a_1$.



언어

- 잘 정의된 언어는 문장으로 구성됨
- 알파벳은 문장을 이루는 기본적인 심볼
- 알파벳 T 는 항상 유한 집합, 반면에 T^* 는 항상 무한집합

언어(Language): 알파벳 T 에 대하여 언어 L 은 T^* 의 **부분집합**

$$L \subseteq T^*$$

- 언어는 T^* 에 속하는 스트링 중 특정 형태만 모은 것
- 유한 언어: 스트링 수가 유한개일 때
- 무한언어: 스트링 수가 무한개일 때



■ 언어 연산

(1) 언어 곱(product)

$$LL' = \{xy \mid x \in L \text{ 그리고 } y \in L'\}$$

(2) 언어 L 의 거듭제곱(powers)은 순환적(recursive)으로 정의된다.

$$L^0 = \{\epsilon\}$$

$$L^n = LL^{n-1} \text{ for } n \geq 1.$$

(3) L^* : 재귀 전이 클로저(reflexive transitive closure)

$$= L^0 \cup L^1 \cup L^2 \cup \dots \cup L^n \cup \dots = \bigcup_{i=0}^{\infty} L^i$$

(4) L^+ : 전이 클로저(transitive closure)

$$= L^1 \cup L^2 \cup \dots \cup L^n \cup \dots$$

$$= L^* - L^0$$



■ 언어 표현의 문제점

(1) 어떻게 언어를 표현할 것인가?

유한 언어는 쉽게 표현할 수 있다.

무한 언어는 유한 표현법이 필요하다.

* 무한 언어의 유한 표현

1. 집합 표현으로 조건제시법
2. 언어 생성 시스템인 문법 : Scheme의 생성
3. 언어의 인식기 : Scheme의 인식

(2) 모든 언어는 유한한 표현을 가지고 있나?

- 항상 모든 언어에 대하여 유한 표현이 존재하는 것은 아니다.



문법

■ 문법

- 무한 언어의 유한 표현 방법

■ 문법 요소

- 단말기호(terminal) : 정의된 언어의 알파벳
- 비단말기호(nonterminal) :
 - 문법에서 스트링을 생성하는데 사용되는 중간 과정의 기호
 - 언어의 구조를 정의하는데 사용
- 문법 기호:
 - 단말기호와 비단말기호를 합한 것으로 보통 V(vocabulary)로 표시
- 생성규칙:
 - $\alpha \rightarrow \beta$
 - α 를 β 구조로 정의한다는 뜻으로 유도과정에서 α 가 β 로 대체됨



■ $G = (V_N, V_T, P, S)$

- V_N : 비단말(nonterminal) 기호들의 유한 집합
- V_T : 단말(terminal) 기호들의 유한 집합
 - $V_N \cap V_T = \emptyset$, $V_N \cup V_T = V$
- P : 생성 규칙들의 유한 집합
 - $\alpha \rightarrow \beta$, $\alpha \in V^+$, $\beta \in V^*$
 - α 는 lhs, β 는 rhs
- S : 시작 심벌(문장 심벌)



■ [예] $G = (\{S, A\}, \{a, b\}, P, S)$

$P :$ $S \rightarrow aAS$ $S \rightarrow a$
 $A \rightarrow SbA$ $A \rightarrow ba$ $A \rightarrow SS$

\Rightarrow $S \rightarrow aAS \mid a$
 $A \rightarrow SbA \mid ba \mid SS$



■ 유도(derivation)

1. \Rightarrow : “직접 생성” 또는 “직접 유도”

if $\alpha \rightarrow \beta \in P$ and $\gamma, \delta \in V^*$ then

$$\gamma \alpha \delta \Rightarrow \gamma \beta \delta$$

2. $\overset{*}{\Rightarrow}$: $\alpha_1, \alpha_2, \dots, \alpha_n \in V^*$ 와 $\alpha_1 \Rightarrow \alpha_2 \Rightarrow \dots \Rightarrow \alpha_n$, 라고 가정하면

$$\alpha_1 \overset{*}{\Rightarrow} \alpha_n$$

(0 번 이상의 유도)

3. $\overset{+}{\Rightarrow}$: 한 번 이상의 유도

참고) $\left[\rightarrow$: 생성 규칙에서 사용.

“대치할 수 있음”

$\left[\Rightarrow$: 유도 과정에서 사용한다.



■ $L(G)$: 문법 G 에 의해 생성되는 언어

$$L(G) = \{\omega \mid S \xrightarrow{*} \omega, \omega \in V_T^*\}$$

☞ ω 는 G 의 문장 형태 S 일 때 $\xrightarrow{*} \omega$ 와 $\omega \in V^*$.

ω 는 G 의 문장 S 일 때 $\xrightarrow{*} \omega$ 와 $\omega \in V_T^*$.

$$\begin{aligned} P : \quad S &\rightarrow aA \mid bB \mid \varepsilon \\ A &\rightarrow bS \\ B &\rightarrow aS \end{aligned}$$

$S \xrightarrow{*} abba$ 유도 과정

$S \Rightarrow aA$	(생성규칙 $S \rightarrow aA$)
$\Rightarrow abS$	(생성규칙 $A \rightarrow bS$)
$\Rightarrow abbB$	(생성규칙 $S \rightarrow bB$)
$\Rightarrow abbaS$	(생성규칙 $B \rightarrow aS$)
$\Rightarrow abba$	(생성규칙 $S \rightarrow \varepsilon$)




■ $G_1 = (\{S\}, \{a\}, P, S)$ 을 이용하여 $L(G_1)$

$P : S \rightarrow a \mid aS$

$L(G_1) = \{ a^n \mid n \geq 1 \}$

■ 언어 설계





■ $G = (\{A, B, C\}, \{a, b, c\}, P, A)$

$$\begin{array}{ll} P : & \begin{array}{l} A \rightarrow abc \\ Bb \rightarrow bB \\ bC \rightarrow Cb \\ aC \rightarrow aa \end{array} & \begin{array}{l} A \rightarrow aBbc \\ Bc \rightarrow Cbcc \\ aC \rightarrow aaB \end{array} \end{array}$$

$$L(G) = \{ a^n b^n c^n \mid n \geq 1 \}$$



다양한 문법 예:

ex1) $S \rightarrow 0S1 \mid 01$

ex2) $S \rightarrow aSb \mid c$

ex3) $A \rightarrow aB$
 $B \rightarrow bB \mid b$

ex4) $A \rightarrow abc$ $A \rightarrow aBbc$
 $Bb \rightarrow bB$ $Bc \rightarrow Cbcc$
 $bC \rightarrow Cb$ $aC \rightarrow aaB$
 $aC \rightarrow aa$



■ 문법 설계

- $L = \{ a^n \mid n \geq 0 \}$ 일 때 문법 :

$A \rightarrow aA \mid \epsilon$

- $L = \{ a^n \mid n \geq 1 \}$ 일 때 문법 :

$A \rightarrow aA \mid a$

- 임베디드 생성

$A \rightarrow aAb \mid ab$

ex1) $L_1 = \{ a^n b^n \mid n \geq 0 \}$

ex2) $L_2 = \{ 0^i 1^j \mid i \neq j, i, j \geq 1 \}$



촘스키 계층 (Chomsky Hierarchy)

■ 노암 촘스키(Noam Chomsky)

■ 생성 형식에 따라

$$\alpha \rightarrow \beta \in P$$

- Type 0 : 제한 없음(unrestricted grammar, UG) (제한되지 않은 문법)
- Type 1 : 문맥 의존 문법(context-sensitive grammar, **CSG**).

$$\alpha \rightarrow \beta, |\alpha| \leq |\beta|$$

- Type 2 : 문맥 자유 문법(context-free grammar, **CFG**).

$$A \rightarrow \alpha, \text{ 여기서 } A : \text{nonterminal}, \alpha \in V^*.$$

- Type 3 : 정규 문법(regular grammar, **RG**).

$$A \rightarrow tB \text{ or } A \rightarrow t, (\text{우선형, right-linear})$$

$$A \rightarrow Bt \text{ or } A \rightarrow t, (\text{좌선형, left-linear})$$

여기서, $A, B : \text{nonterminal}, t \in V_T^*$.



■ 형식 언어


- REL (Recursively Enumerable Language)
- CSL (Context Sensitive Language)
- CFL (Context Free Language)
- RL (Regular Language)

■ 형식 언어의 예

- 단순 매칭 언어 : $L_m = \{a^n b^n \mid n \geq 0\}$ CFL
- 중복 매칭 언어 : $L_{dm} = \{a^n b^n c^n \mid n \geq 0\}$ CSL
- 좌우 대칭 언어 : $L_{mi} = \{\omega\omega^R \mid \omega \in V_T^*\}$ CFL
- 회문 언어 : $L_r = \{\omega \mid \omega = \omega^R\}$ CFL
- 괄호 언어 : $L_p = \{\omega \mid \omega: \text{balanced parenthesis}\}$ CFL



촘스키의 언어 계층





■ 언어 & 인식기

Grammar	Language	Recognizer
type 0 (unrestricted)	recursively enumerable set	Turing machine
type 1 (context-sensitive)	context-sensitive language	linear bounded automata
type 2 (context-free)	context-free language	pushdown automata
type 3 (regular)	regular language	finite automata



인간과 원숭이의 언어 인식 능력 차이

■ 사람 언어 인식

- PSG – type 2 language
- FSG – type 3 language


■ 원숭이의 언어 인식

- FSG – type 3 language

■ FSG: finite state grammar

■ PSG: phrase structure grammar

■ Ref: Fitch and Hauser,
Computational Constraints on
Syntactic Processing in a
Nonhuman Primate, Science Jan.
2004.



* cotton-top tamarin



참고 문헌

- Alfred V. Aho, Ravi Sethi, Jeffrey D. Ullman, “Compilers – Principles, Techniques, and Tools,” Bell Telephone Laboratories, Incorporated, 1986.
- 오세만, “컴파일러 입문”, 정의사, 2004.